MBC 미디어캠퍼스 · AI 기반 데이터 저널리스트 양성 과정

3 주차

도메인에 맞는 뉴스 세팅하기 (2/3)
데이터 수집과 정제, 직접 해보기

① 수집(구글시트 IMPORTXML) → ② 정제(AI 챗봇) 순서로 실습합니다

ORIENTATION

오늘의 학습 목표

01

노코드 수집 실습

구글시트 IMPORTXML 함수로 코드 한 줄 없이 웹페이지 데이터를 직접 수집해본다

02

AI 챗봇 정제 실습

수집한 원자료를 GPTs·Gemini Gems·Claude Projects 중 하나로 다듬어 콘텐츠로 완성한다

03

파이프라인 연결

수집→정제가 실제로 어떻게 이어지는지 손으로 직접 확인한다

PIPELINE 복습

오늘은 ①②단계를 직접 해봅니다



2 주차에서 개념으로 배운 두 단계를, 오늘은 실제 데이터로 손을 움직여 직접 실습합니다.

왜 구글시트로 수집하는가

코드 불필요

함수 하나 (=IMPORTXML) 만 셀에 입력하면 끝 — 별도 프로그램 설치 · 실행 없음

URL 만 교체

강사가 만든 템플릿에 URL 과 추출 위치만 바꾸면 다른 페이지에도 재사용 가능

결과가 바로 표 형태

수집한 데이터가 셀에 바로 채워져 정제 · 필터링이 쉬움

무료

구글 계정만 있으면 별도 비용 없이 사용 가능

IMPORTXML 함수 사용법

```
=IMPORTXML( url , xpath_query )
```

url	데이터를 가져올 웹페이지 주소 (따옴표로 감싸기)
xpath_query	페이지에서 추출할 위치를 지정하는 경로 — 크롬 개발자도구에서 요소 우클릭 → ‘ Copy XPath’ 로 얻을 수 있음

주의 : xpath 와 url 모두 큰따옴표 (") 로 감쌉니다 . 작은따옴표 (') 가 필요한 경우는 xpath 안에 속성값 (예 : @id=' 내용 ') 이 있어 따옴표가 또 필요할 때뿐입니다 — //h1 처럼 단순한 경로는 큰따옴표만으로 충분합니다 .

실습 중 자주 만나는 문제

#N/A 오류	xpath 가 실제 페이지 구조와 다름 — 페이지 구조가 바뀌었거나 요소 선택이 틀림
따옴표 오류	속성값이 있는 xpath(예 : [@id="…"]) 를 그대로 붙여넣어 큰따옴표가 겹칠 때 발생 — 안쪽만 작은따옴표로 교체 . 단순 경로 (//h1 등) 는 큰따옴표만 쓰면 됨
‘ 로드하는 데 시간이 걸림’	시간당 호출 제한 초과 — IMPORTXML 개수를 줄이거나 잠시 후 재시도
빈 결과	자바스크립트로 나중에 그려지는 동적 페이지 — IMPORTXML 은 정적 HTML 만 읽을 수 있음

① 수집 · 실전 확인

실전에서 확인한 사이트별 접근성

연합뉴스	차단	홈페이지 ·RSS 모두 자동 접근 차단 (robots.txt)
한국소비자원	차단	사이트 전체 자동 접근 차단
정책브리핑 (korea.kr)	가능	실제 IMPORTXML 성공 , 텍스트 공공누리 자유이용
식품의약품안전처	가능	실제 접근 확인됨 , 리콜 · 안전 정보 다수
기상청 날씨누리	가능	공식 예보문 , 공공저작물

직접 테스트해보지 않으면 알 수 없습니다 — 같은 정부 사이트라도 차단 여부가 다릅니다 .

핵심 원칙

합법적 AI 데이터 활용 3 원칙

① 합법적 수집 구분 → ② AI 기반 정제 → ③ 사람의 검수

가능 — AI 로 자유롭게 정제

- 공공데이터포털 · 보도자료
- 증시 · 경기 등 사실 수치
- 위키백과 , 공유마당 (CCL)
- 본인이 직접 생산한 콘텐츠

제한 — 사람이 직접 재구성

- 언론사 기사 본문 (연합뉴스 등)
- 유료 구독 콘텐츠
- AI 학습 · 활용 금지 명시 저작물
- ' 변경금지' 조건의 공공누리

① 수집 · 보조 함수

IMPORTHTML · IMPORTFEED 도 함께 알아두기

IMPORTHTML

`=IMPORTHTML(url, “table” 또는 “list”, 순번)`

페이지 안의 표나 목록을 통째로 가져올 때 — xpath 보다 훨씬 간단

IMPORTFEED

`=IMPORTFEED(url)`

언론사 · 블로그의 RSS 주소만 있으면 최신 글 목록을 자동 수집

② 정제 · 복습

정제란 무엇이었는지 복습

2 주차에서 배운 도구들을 오늘은 실제로 만들어 씁니다 .

Gemini Gems

무료 · 구글 계정

ChatGPT GPTs

Plus 이상 유료

Claude Projects

Pro 이상 유료

오늘은 이 중 하나를 골라 '수집한 데이터를 넣으면 정제된 콘텐츠가 나오는' 나만의 챗봇을 직접 완성합니다 .

① + ② 연결

오늘 실습 흐름 — 수집에서 정제까지



2 주차에서 만든 '도메인별 프롬프트 템플릿'을 여기서 그대로 재사용합니다 .

오늘의 실습

수집 → 정제, 손으로 직접 해보기

Part A. 구글시트로 지정된 페이지에서 데이터 수집하기
Part B. 수집한 데이터를 AI 챗봇으로 정제해 콘텐츠 완성하기

다음 주 예고

4 주차 — 도메인에 맞는 뉴스 세팅하기 (3/3)
도메인별 파인튜닝, AI 생성물 검수 · 품질개선 [③ 완료 120h]