[MBC 미디어캠퍼스] AI 기반 데이터 저널리스트 양성 과정 · 3 주차 실습 자료

구글시트 뉴스 수집 — 최종 양식과 수식 (수정판)

구분 · 분야 · URL · 헤드라인 · 기사링크 · 기사원문 — 2 단계 방식으로 확정

전체 구조 (2 단계 방식)

① 목록 페이지 하나에서 헤드라인과 기사링크를 나란히 뽑고, ② 그 기사링크 열을 참조해 본문을 따로 뽑습니다. 두 IMPORTXML 을 한 수식에 억지로 합치는 중첩 방식도 가능은 하지만, 기사 하나만 콕 찍을 때만 되고 여러 기사를 다루기 어려워 이번엔 쓰지 않았습니다.

열	입력 방식	내용
A. 구분	수동	정치 / 경제 / 국제 / 문화 등 대분류를 직접 입력
B. 분야	수동	세부 분야 또는 카테고리명을 직접 입력
C. URL	수동	수집할 목록 페이지 주소 (예: 연합뉴스 정치 전체기사 페이지)
D. 헤드라인	**자동**	① 단계 수식이 C 열의 목록 페이지에서 뽑아낸 제목
E. 기사링크	**자동**	① 단계 수식이 같은 목록 페이지에서 뽑아낸 개별 기사 URL (D 열과 같은 행끼리 짝이 맞음)
F. 기사원문	**자동**	② 단계 수식이 E 열의 개별 기사 URL 을 읽어 본문을 가져옴

① 단계 — 목록 페이지에서 헤드라인 + 링크 나란히 수집

목록 페이지 URL(C 열)을 기준으로, 헤드라인용 수식(D 열)과 링크용 수식(E 열)을 나란히 넣습니다. xpath 끝부분만 다르고 나머지는 동일합니다.

헤드라인 (D 열)

```
=IMPORTXML(C2,
"//*[@id='container']/div[2]/div[2]/div[1]/section/div/ul/li[1]/div/
div/strong")
```

실전에서 확인한 결과, /a/span 까지 안 가고 /strong 에서 멈춰도 그 안의 텍스트를 그대로 가져온다 — 더 짧고 간단한 버전. li[1]은 첫 기사 하나만 지정한 것이고, [1]을 빼면 전체 목록이 여러 행에 자동으로 펼쳐진다(스필).

기사링크 (E 열)

```
=IMPORTXML(C2,
"//*[@id='container']/div[2]/div[2]/div[1]/section/div/ul/li[1]/div/
div/strong/a/@href")
```

헤드라인 수식과 경로는 같고, 끝에 /a/@href 를 붙여 그 태그의 링크 주소(href 속성)를 가져온다. 같은 목록·같은 순서에서 뽑기 때문에 D 열과 자동으로 줄이 맞는다.

② 단계 — 개별 기사 URL 로 본문 가져오기

E 열의 기사링크를 참조해 본문을 가져옵니다. 아래는 E 열 5 행(E5)을 기준으로 한 예시이며, F 열에 넣습니다.

```
=TEXTJOIN(" ", TRUE, IMPORTXML(E5, "//*[@id='articleWrap']//p"))
```

TEXTJOIN 이 여러 문단(<p> 태그)을 공백으로 이어붙여 한 셀에 담는다. //p(앞에 슬래시 두 개)는 'articleWrap 안 어디에 있든 상관없이 p 태그를 전부 찾아라' 는 뜻이라, 페이지 구조를 정확히 몰라도 안전하게 작동한다.

- 이 수식은 스필이 아니라 한 행씩 채워야 한다 — F5 에 넣었으면 F6, F7…은 각각 E6, E7 을 참조하도록 따로 채워야 함 (수식을 아래로 드래그).
- 기사원문은 어디까지나 요약을 위한 참고 자료 — 카드뉴스에 원문을 그대로 옮기지 않는다.

참고 — 중첩 방식(기사 1 개만 다룰 때)

여러 기사가 아니라 관심 기사 하나만 콕 찍어 링크와 본문을 한 수식으로 끝내고 싶다면 아래처럼 중첩할 수도 있습니다. 다만 li[1]처럼 결과가 1 개로 고정될 때만 되고, 목록 전체를 다룰 땐 위 2 단계 방식을 씁니다.

```
=TEXTJOIN(" ", TRUE, IMPORTXML(IMPORTXML(C2,
"//*[@id='container']/div[2]/div[2]/div[1]/section/div/ul/li[1]/div/
div/strong/a/@href"), "//*[@id='articleWrap']//p"))
```

훨씬 편한 방법 — 셀 참조로 따옴표 문제 자체를 없애기

지금까지 xpath 안의 큰따옴표를 작은따옴표로 일일이 바꿔온 이유는, xpath 를 수식 안에 직접 타이핑했기 때문입니다. URL 과 xpath 를 각각 셀에 넣어두고 그 셀을 참조하면, 이 문제 자체가 사라집니다.

```
=IMPORTXML(E2, F2)
```

E2 에 URL, F2 에 xpath 를 그대로 넣어두면 됩니다. 셀 참조는 따옴표로 감쌀 필요가 없고, 셀 안의 xpath 에 큰따옴표가 그대로 들어있어도 문제가 되지 않습니다 — 셀 내용은 수식 문법이 아니라 순수한 값으로만 취급되기 때문입니다.

- 장점 ①: 크롬에서 Copy XPath 로 얻은 값을 변환(따옴표 교체) 없이 그대로 붙여넣을 수 있다
- 장점 ②: 여러 페이지에 같은 xpath 를 재사용할 때, 수식을 아래로 드래그하기만 하면 된다 (스킨큐어 회사 페이지들처럼 컨테이너 id 가 동일한 경우 특히 유용)
- 주의: 셀 안에는 순수한 URL/xpath 텍스트만 넣는다 — 셀 안에 따옴표까지 문자로 포함시키면 (예: "//*[@id='content']") 오히려 오작동한다

오늘 해결한 문제들 (참고용)

따옴표 오류

원인: xpath 안의 속성값(@id="container")에 큰따옴표를 그대로 써서, 수식 전체를 감싸는 큰따옴표와 충돌함

해결: 속성값 안쪽만 작은따옴표(')로 교체: @id='container' — 또는 아예 URL·xpath 를 셀에 넣고 셀 참조로 쓰면(위 '훨씬 편한 방법' 참고) 이 문제 자체가 생기지 않는다

#N/A 오류 (구조 문제)

원인: xpath 경로가 문법상으로는 맞지만, 그 위치에 실제로 일치하는 요소가 없음 (페이지 구조를 잘못 추측함)

해결: 경로를 정확한 절대경로 대신 //p 처럼 '그 안 어디든 찾기' 방식으로 넓혀서 재시도

#N/A 오류 (일시적 오류)

원인: 다른 행은 같은 수식으로 멀쩡한데 특정 셀만 #N/A — IMPORTXML 을 짧은 시간에 여러 번 호출하면 가끔 응답이 꼬여서 무작위로 발생

해결: 그 셀만 지우고 다시 입력, 또는 시트 새로고침(F5). 여러 개가 한꺼번에 실패하면 시간당 호출 제한일 수 있으니 잠시 후 재시도

URL 이 한글 제목으로 바뀜

원인: 구글시트의 '스마트 칩' 기능이 URL 을 페이지 제목 카드로 자동 변환

해결: 붙여넣을 때 Ctrl+Shift+V(값만 붙여넣기) 사용, 이미 바뀐 셀은 팝업에서 '링크를 텍스트로 변환' 선택

헤드라인이 2~3 개만 나옴

원인: '헤드라인 뉴스' 처럼 편집자가 따로 고른 소수의 기사만 모아놓은 영역의 xpath 를 사용함

해결: '전체기사' 목록 영역에서 다시 Copy XPath 로 얻어 교체

다음 할 일

이 구조(A 구분·B 분야·C URL·D 헤드라인·E 기사링크·F 기사원문)가 안정적으로 작동하는 것을 확인했으니, 다음 단계로 구글시트 템플릿 파일과 AI 정제 프롬프트(F 열 기사원문을 근거로 헤드라인·요약을 새로 쓰도록)를 이 양식에 맞춰 업데이트합니다.