3 주차 실습 워크시트

데이터 수집(구글시트 IMPORTXML, 6 열 구조) + 저작권 확인 + 정제(AI 챗봇) 직접 해보기

실습 순서

- Part A: 구글시트에서 IMPORTXML 로 목록 페이지의 헤드라인·기사링크·기사내용까지 수집한다 (6 열 구조).
- Part B: 수집한 출처의 저작권 유형을 먼저 확인한 뒤, AI 챗봇으로 정제한다.
- 막히는 부분이 있으면 슬라이드의 ‘실전에서 확인한 사이트별 접근성’, ‘흔한 오류와 한계’ 표를 먼저 확인한다.

Part A. 데이터 수집 — IMPORTXML 실습 (6 열 구조)

최종 목표 구조: A 구분 · B 분야 · C URL(목록) · D 헤드라인 · E 기사링크 · F 기사내용 — 모두 수동인 A·B·C 를 채우면 D·E·F 는 수식으로 자동 채워집니다.

① 준비 연습 (강사 제공 페이지)

아래 함수를 새 구글시트 A1 셀에 그대로 입력해보세요.

```
=IMPORTXML("https://ko.wikipedia.org/wiki/대한민국", "//h1")
```

A1 에 어떤 값이 나왔는지 적어보세요:

---

② 목록 페이지에서 헤드라인 + 기사링크 수집

강사가 안내한(또는 3 주차 참고자료 '수집 소재 리스트업'에서 고른) 목록 페이지에서, 기사 제목 하나를 크롬 개발자도구로 우클릭 → 검사 → Copy XPath 로 얻은 뒤 완성하세요.

C. 목록 페이지 URL:

Copy XPath 로 얻은 경로 (순번 [1] 등은 지우고 전체를 가져오게 만들 것):

D. 헤드라인 수식 (=IMPORTXML(C2, ...)):

E. 기사링크 수식 (같은 경로 끝에 /@href 추가):

---

③ 기사링크가 상대경로로 나온다면

사이트에 따라 E 열에 전체 주소가 아니라 '?menukey=...'처럼 일부만 나올 수 있습니다. 이 경우 기본 주소를 앞에 붙여야 합니다.

```
="https://사이트기본주소"&E2
```

④ 개별 기사 본문(F 열) 수집

완전한 기사링크가 나온 셀을 참조해 본문을 가져옵니다. 개별 기사 페이지에서 본문 부분을 다시 Inspect 해서 xpath 를 얻으세요.

본문 xpath:

F. 기사내용 수식 (=TEXTJOIN(" ", TRUE, IMPORTXML(...))):

⑤ 오류가 났다면

어떤 오류(따옴표·#N/A·일시적 오류·상대경로 등)였는지, 어떻게 해결했는지 적어보세요.

Part B. 데이터 정제 — 저작권 확인 + AI 챗봇 실습

① 저작권 유형 먼저 확인

수집한 사이트가 언론사인지 공공기관인지, 공공기관이라면 공공누리 몇 유형인지 확인하세요.

출처 종류: ☐ 언론사(저작권 있음) ☐ 공공기관 — 공공누리 (☐ 1 유형 ☐ 2 유형 ☐ 3 유형(변경금지) ☐ 4 유형(변경금지))

'변경금지' 가 있거나 언론사 저작물이라면 → AI 에게 원문을 통째로 넣지 말고, 아래 ②를 '사람이 먼저 요약 → AI 는 표현만 다듬기' 로 진행하세요.

② 사용할 도구

☐ Gemini Gems ☐ ChatGPT GPTs ☐ Claude Projects (하나에 체크)

③ 정제 프롬프트 작성

F 열(기사내용)을 근거로 삼도록 프롬프트를 작성하세요. (저작권 제한이 있다면 F 열 대신 직접 쓴 요약문을 근거로 삼습니다.)

고른 도메인: ☐ 뉴스 ☐ 브랜드 ☐ 트렌드

완성한 프롬프트 전체:

---

④ 결과 확인

AI 가 만들어준 정제 결과:

---

⑤ 검수

1 주차에서 배운 '사람의 검수' 원칙에 따라, F 열 원문과 대조해 수치·사실관계가 정확한지 확인하고 적어보세요.

오늘의 정리

수집(①)과 정제(②)를 직접 연결해보니, 어느 단계가 가장 시간이 오래 걸렸나요? 저작권 확인 단계는 왜 필요했나요?
